

Predicción de Riesgo Cardiovascular en Radiografías de Tórax con Deep Learning y Grad-CAM

Catalina Maya Iregui CC: 1193089503. Nataly Rodriguez Atehortua CC: 1001505918. Roberto Benitez CC: 1152707847. Valery Quiroga CC: 1152222256

1. Contexto de aplicación

Las enfermedades cardiovasculares representan la principal causa de mortalidad a nivel mundial (Weiss et al., 2024). Para abordar esta problemática las directrices internacionales recomiendan una evaluación continua del riesgo de enfermedades cardiovasculares a partir de los 40 años, considerando factores como la edad, el sexo, la presión arterial, el perfil lipídico y el historial de tabaquismo para estimar el riesgo de eventos cardiovasculares fatales a 10 años (Liao et al., 2023). Este cálculo, avalado por el American College of Cardiology y la American Heart Association, guía la toma de decisiones sobre tratamientos farmacológicos y estrategias de prevención primaria (Liao et al., 2023).

En la actualidad las evaluaciones globales del riesgo cardiovascular suelen ser inexactas y carecen de evidencia sólida sobre la reducción directa de la morbilidad o mortalidad cardiovascular (Liao et al., 2023). Asimismo, las variables necesarias para calcular los puntajes utilizados en la prevención primaria de enfermedades cardiovasculares suelen no estar disponibles en los registros médicos electrónicos (EMR) (Weiss et al., 2024). Por lo tanto, es necesario contar con herramientas de estratificación de riesgo que ofrezcan métodos diversos y accesibles, utilizando datos comúnmente disponibles en los EMR como es el caso de las radiografías de tórax (CXR) (Weiss et al., 2024).

2. Objetivo de machine learning

Este trabajo busca desarrollar un modelo de Deep Learning (DL) para analizar radiografías de tórax y predecir el riesgo de eventos cardiovasculares mayores (MACE), como infartos de miocardio, en un horizonte de 7 años. El objetivo es clasificar a los pacientes estimando la probabilidad de mortalidad, generando un resultado binario de supervivencia o fallecimiento. Esta identificación temprana permitirá optimizar la toma de decisiones y la gestión clínica.

Para añadir interpretabilidad al modelo, se incorporará Grad-CAM (Gradient-weighted Class Activation Mapping), que resalta las áreas de las radiografías que influyen en las predicciones del modelo (DataScientest, 2021). Esto facilita la interpretación de los resultados por parte de los clínicos, mejorando la confianza en el uso del modelo.

3. Dataset

Para el desarrollo de este trabajo se cuenta con un dataset que contiene la información de 5195 pacientes diferentes (equivalentes a 1.241 teras en disco), de los cuales se cuentan con información estructurada de las siguientes variables:

Tipo de variable	Variable	Descripción
Cualitativa	Estado	Variable a predecir. Indica si el paciente falleció o está vivo.
Cualitativa	Tipo de documento	Representa el tipo de ID del paciente.
Cualitativa	Número de documento	Número de ID del paciente.
Cuantitativa	Edad	Edad en años del paciente.
Cualitativa	Fecha nacimiento	Fecha en formato dd/mm/yyyy del nacimiento del paciente.
Cualitativa	Sexo	Sexo del paciente.
Cualitativa	Fecha inicio al programa	Fecha en formato dd/mm/yyyy en que el paciente ingresa al programa de riesgo cardiovascular.
Cualitativa	Fecha fallecimiento	Fecha en formato dd/mm/yyyy en que el paciente falleces, si aplica. Si no, dice No aplica.
Cualitativa	Estado de tabaquismo	Indica si el paciente es: exfumador, fumador activo o no fuma.
Cualitativa	Diagnóstico de diabetes	Variable binaria, que indica si el paciente tiene o no diabetes.
Cuantitativa	Presión arterial sistólica	Presión arterial promedio del paciente en milímetros de mercurio, en caso de no tenerla disponible dice: No disponible.

Cualitativa	Fecha colesterol total y colesterol de lipoproteínas de alta densidad (total- and high-density lipoprotein cholesterol)	Fecha en formato dd/mm/yyyy en que el paciente se realiza el control final del examen de colesterol total y de lipoproteínas.
Cuantitativo	Resultado colesterol total y colesterol de lipoproteínas de alta densidad (total- and high-density lipoprotein cholesterol)	Resultado el paciente se realiza el control final del examen de colesterol total y de lipoproteínas.
Cualitativa	Tiene electrocardiograma	Si posee un estudio de electrograma.
Cualitativa	Último EKG	Fecha en formato dd/mm/yyyy del último electrocardiograma, si posee, si no se asigna No Disponible

Adicional a la información anterior se tienen las imágenes correspondientes a **Radiografía de tórax (P.A. O A.P. y lateral decúbito lateral oblicuas o lateral)**

4. Métricas de desempeño

Machine Learning: Se evaluará el desempeño del modelo de Deep Learning utilizando métricas como AUC-ROC, precisión, sensibilidad, F1-score, matriz de confusión y el coeficiente kappa de Cohen. Un AUC-ROC superior a 0.75 indicará una buena discriminación del modelo. Se considera adecuado un balance entre detección de alto riesgo y falsos positivos si la sensibilidad supera el 75% y la precisión el 80%. El F1-score evaluará el equilibrio entre precisión y sensibilidad, mientras que el kappa de Cohen medirá la concordancia, siendo ideal un valor cercano a 1 y objetivo mayor a 0.5.

Negocio: Los beneficios que podrá obtener la clínica se pueden desglosar desde varios aspectos importantes: Primero en el **diagnóstico**; la implementación del modelo ayudara a los médicos a identificar patrones que podrían ser difíciles de detectar para el ojo humano, permitiendo diagnósticos más tempranos y precisos. Con el método Grad-Cam se visualizan las áreas que influyen en la predicción, lo que genera confianza en el uso de IA y mejora la colaboración entre médicos y tecnólogos. Segundo en la **gestión clínica**; facilitando la gestión de pacientes críticos mediante la estratificación por riesgo, priorizando recursos y tratamientos, reduciendo errores diagnósticos, y estandarizando diagnósticos y tratamientos, lo que disminuye los costos por errores o intervenciones tardías.

Adicional de la **mejora continua**; el personal médico capacitado puede usar el modelo como complemento a su criterio clínico y proporcionar retroalimentación para ajustarlo y actualizarlo conforme a nuevas variables clínicas. Y, por último, **oportunidades**; Grad-CAM permite evaluar el progreso clínico y generar hipótesis para futuras investigaciones, además de servir como herramienta educativa para la formación de residentes en la interpretación de imágenes radiológicas.

5. Resultados previos

Ref	Tittle	Technique	Database	Classification /Output	Accuracy/ AUC
(Weiss et al., 2024)	Deep Learning to Estimate Cardiovascular Risk From Chest Radiographs	Modelo de aprendizaje profundo a partir de radiografías de Torax.	Pacientes con riesgo de enfermedad cardiovascular aterosclerótica. 8869 con riesgo desconocido y en 2132 con riesgo conocido	Probabilidad de muerte cardiovascular entre 0 y 1	No se especifica
(Kamel et al., 2021)	Prediction of Coronary Artery Calcium and CardiovascularRisk on Chest Radiographs Using Deep Learning	Redes neuronales convolucionales profundas (DCNNs)	1689 radiografías de pacientes que se sometieron a una tomografía computarizada cardíaca y radiografía de tórax dentro del mismo año, entre 2013 y 2018	Binaria (1 y 0)	AUC: de 0,70 a 0,74
(Ueda et al., 2022)	Artificial intelligence-based detection of aortic	Modelos de aprendizaje profundo: InceptionV3, ResNet50 y DenseNet121	10433 radiografías de tórax de 5638 pacientes	Binaria	Accuracy: 71%

	stenosis from chest radiographs	Función de activación sigmoide.			
(Matsumoto et al., 2020)	Diagnosing Heart Failure from Chest X-Ray Images Using Deep Learning	Transfer Learning con el modelo VGG16 (red neuronal convolucional con 16 capas)	952 radiografías de tórax	Binaria (Normal y Heart Failure)	Accuracy: 82%
(D'Ancona et al., 2023)	Deep learning to detect significant coronary artery disease from plain chest radiographs AI4CAD	Redes neuronales convolucionales profundas (DCNNs)	7728 pacientes	Binaria (1 y 0) Predicción de enfermedad arterial coronaria (CAD) severo	AUC: de 0.73 a 0.77
(Kusunose et al., 2020)	Deep learning to predict elevated pulmonary artery pressure in patients with suspected pulmonary hypertension using standard chest X ray	Modelo basado en una red de cápsulas, con la adición de bloques residuales. La red consta de seis bloques residuales, seis capas de convolución y seis normalizaciones por lotes. Función de activación ReLu	900 pacientes	Binaria (With predicted pulmonary hypertension (PH), without predicted PH)	AUC: de 0,6 a 0,71

6. Referencias

- D'Ancona, G., Massucci, M., Savardi, M., Signoroni, A., Di Bacco, L., Farina, D., Metra, M., Maroldi, R., Muneretto, C., Ince, H., Costabile, D., Murero, M., Chizzola, G., Curello, S., & Benussi, S. (2023). Deep learning to detect significant coronary artery disease from plain chest radiographs AI4CAD. *International Journal of Cardiology*, 370(August 2022), 435–441. <https://doi.org/10.1016/j.ijcard.2022.10.154>
- DataScientest. (2021). ¿Qué es el método Grad-CAM? <https://datascientest.com/es/que-es-el-metodo-grad-cam>
- Kamel, P. I., Yi, P. H., Sair, H. I., & Lin, C. T. (2021). Prediction of coronary artery calcium and cardiovascular risk on chest radiographs using deep learning. *Radiology: Cardiothoracic Imaging*, 3(3). <https://doi.org/10.1148/ryct.2021200486>
- Kusunose, K., Hirata, Y., Tsuji, T., Kotoku, J., & Sata, M. (2020). Deep learning to predict elevated pulmonary artery pressure in patients with suspected pulmonary hypertension using standard chest X ray. *Scientific Reports*, 10(1), 1–8. <https://doi.org/10.1038/s41598-020-76359-w>
- Liao, H. C., Lin, C., Wang, C. H., & Fang, W. H. (2023). The deep learning algorithm estimates chest radiograph-based sex and age as independent risk factors for future cardiovascular outcomes. *Digital Health*, 9. <https://doi.org/10.1177/20552076231191055>
- Matsumoto, T., Kodera, S., Shinohara, H., Ieki, H., Yamaguchi, T., Higashikuni, Y., Kiyosue, A., Ito, K., Ando, J., Takimoto, E., Akazawa, H., Morita, H., & Komuro, I. (2020). Diagnosing heart failure from chest X-ray images using deep learning. *International Heart Journal*, 61(4), 781–786. <https://doi.org/10.1536/ihj.19-714>
- Ueda, D., Yamamoto, A., Ehara, S., Iwata, S., Abo, K., Walston, S. L., Matsumoto, T., Shimazaki, A., Yoshiyama, M., & Miki, Y. (2022). Artificial intelligence-based detection of aortic stenosis from chest radiographs. *European Heart Journal - Digital Health*, 3(1), 20–28. <https://doi.org/10.1093/ehjdh/ztac102>
- Weiss, J., Raghu, V. K., Paruchuri, K., Zinzuwadia, A., Natarajan, P., Aerts, H. J. W. L., & Lu, M. T. (2024). Deep Learning to Estimate Cardiovascular Risk From Chest Radiographs. *Annals of Internal Medicine*, 177(4), 409–417. <https://doi.org/10.7326/M23-1898>